

第一课

1. 计算方法研究的是运用计算机来解决各种数学问题的**近似**计算方法与理论。是研究各类数学问题在一定范围内的数值解的方法，以及这些方法的误差传播规律、收敛性、稳定性，与如何在计算机上编程有效实现等问题的学科。
2. 误差：看第一课

第二课

计算方法的稳定性：用一个计算方法进行计算时，如果初始数据误差或某一步计算的误差在以后的计算过程中不增长，就称该方法数值稳定；否则，若误差增长，就称该方法数值不稳定

原则：

1. 避免相近数字相减
2. 加法中，防止大数吃小数
3. 避免采用绝对值很小的数做分母
4. 简化运算步骤，减小运算次数
5. 控制计算方法的误差传播，保证计算方法的稳定性

非线性方程的数值解法

目录：

- 二分法
- 一般迭代法：不动点迭代法、加速收敛迭代法
- 牛顿迭代法
- 弦截法

二分法

- 零点/根： x 满足 $f(x) = 0$ ，则 x 称为 f 的根
- m重零点/根： $f(x)$ 能分解为 $f(x) = (x - x^*)^m g(x)$ ， $g(x)$ 不为0，则 x^* 是 $f(x)$ 的m重根

二分法就是满足 $f(a)f(b) < 0$ 的前提下不断取中点，最终取得近似解。

一般迭代法

不动点迭代法

$f(x) = 0$ 变换为 $x = \Phi(x)$ ，也就是 $f(x) = \Phi(x) - x \Rightarrow$ 通过迭代： $x_{k+1} = \Phi(x_k)$ 。但这个迭代并不是一定收敛，所以给出以下收敛定理：

收敛性： $\Phi(x) \in [a, b]$ ，如果：

1. $\forall x \in [a, b]$ ，有 $\Phi(x) \in [a, b]$ (也就是大家都在自变量规定的正方形上)
2. $\exists L < 1, \forall x, y \in [a, b], |\Phi(x) - \Phi(y)| \leq L|x - y| \Rightarrow \frac{|\Phi(x) - \Phi(y)|}{|x - y|} \leq L$ ，也就是导数在此区间小于1。L称为压缩系数

那么 $\Phi(x)$ 在这个区间上有唯一不动点 x^* ，其中误差： $|x^* - x_k| \leq \frac{L^k}{1-L} |x_1 - x_0|$ ， L^k 中的 k 表示的是次方

局部收敛： $x \in U(x^*)$ ， x 在精确解 x^* 邻域附近，如果 $|\Phi'(x)| < 1$ ，则在 $U(x)$ 局部收敛。越接近，收敛越快

全局收敛： $x = \Phi(x)$ 满足收敛性质1、2(导数 < 1)，那么就是在 $[a, b]$ 的全局收敛

✎为求方程 $x^3 - x^2 - 1 = 0$ 在 $x_0 = 1.5$ 附近的一个根, 设将方程改写成下列等价形式,

并建立相应的迭代公式.

(1) $x = 1 + 1/x^2$, 迭代公式 $x_{k+1} = 1 + 1/x_k^2$

(2) $x^2 = 1 + x^3$, 迭代公式 $x_{k+1} = \sqrt{1 + x_k^3}$

(3) $x^2 = \frac{1}{x-1}$, 迭代公式 $x_{k+1} = 1/\sqrt{x_k-1}$

试分析每种迭代公式的收敛性, 并选取一种公式求出具有四位有效数字的近似根.

$f(1.4) \approx -0.216 < 0, f(1.5) \approx 0.125 > 0, \Rightarrow f(1.4)f(1.5) < 0 \Rightarrow [1.4, 1.5]$ 为有根区间
 $f(x)$ 在 $[1.4, 1.5]$ 连续

(1) $\varphi(x) = 1 + \frac{1}{x^2}, \varphi'(x) = -\frac{2}{x^3} \Rightarrow |\varphi'(x)| \leq |\varphi'(1.4)| = 0.219 < 1 \Rightarrow$ 收敛

(2) $\varphi(x) = \sqrt{1+x^3}, \varphi'(x) = \frac{3x^2}{2\sqrt{1+x^3}} \Rightarrow |\varphi'(x)| \leq \frac{2 \times 1.5^2}{2\sqrt{1+1.5^3}} \approx 0.485 < 1 \Rightarrow$ 收敛

(3) $\varphi(x) = \frac{1}{\sqrt{x-1}}, \varphi'(x) = -\frac{1}{2(x-1)^{3/2}} \Rightarrow |\varphi'(x)| \geq |\varphi'(1.5)| = 1.414 > 1 \Rightarrow$ 发散

由(1) $x_{k+1} = \sqrt[3]{1+x_k^3}, \text{取 } x_0 = 1.5, x_1 = 1.481248024, x_2 = 1.471705173, x_3 = 1.466817214, x_4 = 1.4667047973, x_5 = 1.466624301, x_6 = 1.466587682 \Rightarrow x^* \approx 1.4666$

收敛的阶数：

设迭代 $x_{k+1} = \Phi(x)$, 满足 $\lim_{n \rightarrow \infty} \frac{x_{n+1} - x^*}{(x_n - x^*)^p} = k, k$ 是常数。

则该迭代是 p 阶收敛

其中： $p = 1$ 是线性收敛， > 1 是超线性收敛， $= 2$ 是平方收敛。

定理： $x_{k+1} = \Phi(x_k)$ ，如果 $\Phi'(x^*) = \Phi''(x^*) = \dots = \Phi^{(p-1)}(x^*) = 0, \Phi^{(p)}(x^*) \neq 0$ ，则其 p 阶收敛。

斯特芬森加速迭代法

公式：
$$x_{k+1} = x_k - \frac{(\Phi(x_k) - x_k)^2}{\Phi(\Phi(x_k)) - 2\Phi(x_k) + x_k}$$

牛顿迭代法

牛顿法(切线法)-main

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \quad k = 0, 1, 2, \dots$$

收敛性(使用条件:导数≠0): 若 $f'(x^*) \neq 0, f''(x^*) \neq 0$, 则牛顿法二阶收敛。且 $\lim_{k \rightarrow \infty} \frac{x_{k+1} - x}{(x_k - x^*)^2} = \frac{f''(x^*)}{2f'(x^*)}$

牛顿法的局部收敛性:

如果 $f'(x^*) \neq 0$, 则在 $U(x^*)$ 至少二阶收敛

$$\because \Phi'(x) = \frac{f(x)f''(x)}{[f'(x)]^2} \Rightarrow \therefore |\Phi(x^*)| = 0 < 1$$

$$\Phi''(x) = \frac{[[f''(x)]^2 + f(x)f'''(x)][f'(x)]^2 - 2f'(x)[f''(x)]^2 f(x)}{[f'(x)]^4} = \left| \frac{f''(x)}{f'(x)} \right|^2$$

区间收敛性: 设求 $f(x) = 0$, 且 $f(x)$ 二阶导数存在

如果: (1) $f(a)f(b) < 0$

(2) $\forall x \in [a, b], f'(x) \neq 0, f''(x) \neq 0$ (也就是不变号、凹凸性)

(3) 初值 $x_0 \in [a, b], f(x)f''(x_0) > 0$

则 (1) $f(x) = 0$ 在 $[a, b]$ 有唯一确定根

(2) 牛顿法二阶收敛

应用牛顿法于方程 $f(x) = 1 - \frac{a}{x^2} = 0$, 导出求 $\sqrt{a}$ 的迭代公式, 并用此公式求 $\sqrt{115}$ 的值.
(结果精确到小数点后6位)

$$y_{k+1} = y_k - \frac{f(y_k)}{f'(y_k)} = y_k - \frac{1 - \frac{a}{y_k^2}}{2 \cdot \frac{a}{y_k^3}} = \frac{y_k}{2} \left(1 + \frac{a}{y_k^2} \right)$$

$$\because f'(x) = 1 - \frac{a}{x^2} \Rightarrow f'(x) = \frac{2x^2 - a}{x^3}, \quad f''(x) = -\frac{2a}{x^4} < 0$$

显然, $x=0$ 为 $f(x)$ 的间断点, 当 $x > 0$ 时 $f'(x) \neq 0, f''(x) \neq 0$

要 $f(x_0)f''(x_0) > 0 \Rightarrow 0 < x_0 < \sqrt{a}$

当 $0 = 115$ 时, $y_0 = \frac{y_1}{2} \left(1 + \frac{115}{y_1^2} \right), y_0 \in (0, \sqrt{115})$

取 $y_0 = 10$, 则 $y_1 = 10.55217391, y_2 = 10.7181839$

$y_3 = 10.7181839, y_4 = 10.7181839$

$\therefore \sqrt{115} = 10.7181839$



简化牛顿法(平行弦法)

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_0)}, \quad \text{即导数不变。}$$

牛顿下山法

$$x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)}, \quad \text{其中 } \lambda \text{ 为下山因子}$$

λ 从 1 开始取: $\lambda = 1, \frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \dots$, 直到有满足的下山条件: $|f(x_{k+1})| < |f(x_k)|$

弦截法(割线法)

$$x_{k+1} = x_k - \frac{f(x_k)}{f(x_k) - f(x_{k-1})} (x_k - x_{k-1})$$

即用差商(割线) $\frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$ 代替 $f'(x)$

注意: 此法必须给出两个初始值 x_0, x_1

解线性方程组的直接法

目录:

- 高斯消去法
- 列主元(全主元)高斯消去法
- LU分解法(矩阵三角分解法)
- 解三角方程组的追赶法

高斯消去法

高斯消去法: $\begin{bmatrix} | & & \\ A & & \\ | & & \end{bmatrix} \begin{bmatrix} | \\ X \\ | \end{bmatrix} = \begin{bmatrix} | \\ b \\ | \end{bmatrix}$, 即 $AX=b$

写出增广矩阵 $[A:b]$, 进行行初等变换 $\rightarrow \begin{bmatrix} | & & & | \\ 0 & 1 & & | \\ 0 & 0 & 1 & | \\ 0 & 0 & 0 & | \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix}$

列主元消去法(对角线元素绝对值最大)

例: $Ax=b$, 求 x 并求 $\det(A)$

$$\left. \begin{matrix} 12x_1 - 3x_2 + x_3 = 15 \\ -18x_1 + 3x_2 - x_3 = -15 \\ x_1 + x_2 + x_3 = 6 \end{matrix} \right\} = \text{增广矩阵} \begin{bmatrix} 12 & -3 & 3 & 15 \\ -18 & 3 & -1 & -15 \\ 1 & 1 & 1 & 6 \end{bmatrix} \rightarrow \begin{bmatrix} -18 & 3 & -1 & -15 \\ 12 & -3 & 3 & 15 \\ 1 & 1 & 1 & 6 \end{bmatrix} \rightarrow \begin{bmatrix} -18 & 3 & -1 & -15 \\ 0 & -1 & \frac{7}{3} & 5 \\ 0 & 0 & \frac{11}{3} & 11 \end{bmatrix} \text{解出} x = [1, \frac{1}{3}, \frac{1}{3}]^T$$

矩阵的LU分解

设A为n阶矩阵，若A的顺序主子式 $D_i \neq 0 (i = 1, 2, \dots, n - 1)$ ，则A可以分解为一个**单位**下三角矩阵L(主对角线为1)和一个上三角矩阵U，且分解唯一。即：

$$\left. \begin{matrix} A = LU \\ Ax = b \end{matrix} \right\} \Rightarrow LUx = b \Rightarrow \begin{matrix} Ly = b & \text{先求这个} \\ Ux = y & \text{再求这个} \end{matrix} A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ \textcircled{1} & 1 & 0 & 0 \\ \textcircled{1} & \textcircled{3} & 1 & 0 \\ \textcircled{1} & \textcircled{3} & \textcircled{5} & 1 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ 0 & \textcircled{2} & \textcircled{2} & \textcircled{2} \\ 0 & 0 & \textcircled{4} & \textcircled{4} \\ 0 & 0 & 0 & \textcircled{6} \end{bmatrix} a_{1j} \text{就是} A \text{中的第一行的值}$$

LU两个矩阵中的值的解算根据上述序号来解。利用矩阵乘法来解(行×列=A中对应元素)

改进的平方根法(LU课外)：

1. 对称矩阵：

设A为n阶对称矩阵，且A的所有顺序主子式都不为零，则可以将A=LU中的U变换为 DL^T ，也就是 $A = LU = LDL^T$ ，其中L是单位下三角矩阵，D是**对角**矩阵(主对角线以外的元素全是零)。

先A=LU解出L和U，然后再 $A = LDL^T$ ，D的主对角元素就是U的主对角元素，然后就是 $Ly = b, DL^Tx = y$

2.对称正定矩阵：

设A为对称正定矩阵，则存在下三角矩阵， $A = LL^T$ ，此处的L和 $A = LU$ 中的L不一样

一般用(1): $Ly = b, DL^Tx = y$ 就行了，(2)用不上知道有这种方法就行，一切以 $A = LU$ 为主。

追赶法

对于严格对角占优的三对角矩阵，可分解为新的A=LU，其中L为下三角矩阵，U为单位上三角矩阵。 $Ax = b \Rightarrow Ux = y, Ly = b$ 。对比之前的LU分解法可以说是一样的，三对角矩阵也是这么分解。

$$A = \begin{bmatrix} a_{11} & a_{12} & & & \\ a_{21} & a_{22} & a_{23} & & \\ & a_{32} & a_{33} & a_{34} & \\ & & a_{43} & a_{44} & a_{45} \\ & & & a_{54} & a_{55} \end{bmatrix} = \begin{bmatrix} a_{11} & & & & \\ a_{21} & \textcircled{2} & & & \\ & a_{32} & \textcircled{4} & & \\ & & a_{43} & \textcircled{6} & \\ & & & a_{54} & \textcircled{8} \end{bmatrix} \begin{bmatrix} 1 & \textcircled{1} & & & \\ & 1 & \textcircled{3} & & \\ & & 1 & \textcircled{5} & \\ & & & 1 & \textcircled{7} \\ & & & & 1 \end{bmatrix}$$

本质和LU分解法一样，根据矩阵内的序号，用矩阵乘法定义来进行求解序号的值。为什么被单独列出来，是因为它利用了对角矩阵的稀疏性，

误差分析

目录：

- 矩阵的范数
- 矩阵的条件数

解线性方程组的误差分析

目录：

- 范数定义
- 向量、矩阵范数
- 方程组系数矩阵的条件数与误差分析

范数定义

设 R^n 是n维空间实向量， $||\cdot||$ 是一种函数关系，满足以下条件：

- $||A|| \geq 0, (||A|| = 0 \Leftrightarrow A = 0)$
- $||cA|| = |c| \cdot ||A||, c \in R$
- $||A + B|| \leq ||A|| + ||B||, ||x|| - ||y|| \leq ||x - y||$
- $||AB|| \leq ||A|| \cdot ||B||$

则称 $||\cdot||$ 是 R^n 上的一种范数(长度)

向量、矩阵范数

向量: $X = [x_1, x_2, \dots, x_n]^T$ ， $\sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$ 称为向量的长度。

向量范数

设向量 $X \in R^n$ ，并且符合范数定义。

向量的n阶范数为： $||X||_n = (\sum_{i=1}^n |x^n|)^{\frac{1}{n}}$ ，无穷范数为 $||X||_\infty = \max |x_i|, 1 \leq i \leq n$ 。常用的范数是：一阶、二阶、无穷。

范数等价定理：设 $\|\cdot\|_A$ 和 $\|\cdot\|_B$ 是 R^n 中两种不同的范数，则存在与 x 无关的常数 C_1, C_2 ，使得 $C_1\|X\|_B \leq \|X\|_A \leq C_2\|X\|_B, X \in R^n$

向量序列的收敛定义

定义 5.2 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中一向量序列, $x^{(k)} = (x_1^{(k)}, \dots, x_n^{(k)})^T$, $x^* = (x_1^*, \dots, x_n^*)^T \in \mathbb{R}^n$, 若 $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*, (i = 1, 2, \dots, n)$, 则称 $\{x^{(k)}\}$ 收敛于 x^* . 记为 $\lim_{k \rightarrow \infty} x^{(k)} = x^*$ 或 $x^{(k)} \rightarrow x^* (k \rightarrow \infty)$.

由范数等价定理可证：设 $\|x\|$ 为 $\mathbb{R}^n$ 中任意一种向量范数，则

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \Leftrightarrow \lim_{k \rightarrow \infty} \|x^{(k)} - x^*\| = 0$$

要证明一个向量序列收敛，只需要选择一种具体范数去证明。选择适当的范数能使证明简化。

矩阵范数

设矩阵 $A \in R^{n \times n}$ 某个非负实值函数 $N(A) = \|A\|$ 满足范数定义，则称 $N(A)$ 是 $R^{n \times n}$ 上的一个矩阵范数(长度/模)。

矩阵范数的性质可以由向量范数定义直接验证：

1. 设 $A \neq 0, \exists x \neq 0 \rightarrow Ax \neq 0$ ，根据向量范数性质有： $\|Ax\| > 0$ ，所以：

- $\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} > 0$
 - 当 $A = 0$ 时， $\exists x \neq 0$ ，使得 $\|Ax\| = 0$ ，则 $\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = 0$
- 矩阵 A 的范数就是 $\frac{\|Ax\|}{\|x\|}$ 的最大值，当它也称为算子范数。

2. 根据以上可以验证其拥有的范数性质。

矩阵范数计算公式：

- A 的无穷范数，也称为行范数： $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$ ，就是求每一行绝对值相加，最大的那个就是行范数。
- $\|A\|_1$ ，一阶范数也就是列范数，就是每一列元素绝对值相加，和行范数翻过类。
- 2范数： $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$, $\lambda_{\max}$ 是 $A^T A$ 的最大特征值。注意这里根号下只有一个 λ ，后面只是表示它是 $A^T A$ 所有特征值中最大的那个而已。
- F范数： $\|A\|_F = (\sum_{i,j=1}^n a_{ij}^2)^{\frac{1}{2}}$ ，就是矩阵所有元素平方相加再开根。
- 矩阵特征值快速计算(二阶): $\lambda^2 - tr(A)\lambda + |A| = 0$

谱半径

矩阵特征值 $\lambda_i, i = 1, 2, \dots, n$ ，绝对值最大的就是矩阵的谱半径，记为 $\rho(A), \rho(A) = \lambda_{absmax}$

定理：

- 设有一方阵，任意的该矩阵范数都有 $\rho(A) < \|A\|$ ，也就是矩阵的谱半径小于任何该矩阵的范数。
- 如果 $A \in R^{n \times n}$ 是对称矩阵,则 $\rho(A) = \|A\|_2$
- (不怎么考)如果方阵 B 满足 $\|B\| < 1$ ，则 $I \pm B$ 为非奇异阵，且 $\|(I \pm B)^{-1}\| \leq \frac{1}{1-\|B\|}$

方程组系数矩阵的条件数与误差分析

- 条件数： $cond(A)_r = \|A^{-1}\|_r \cdot \|A\|_r, r = 1, 2, \infty$ 。
- 谱条件数(特殊形式) $cond(A)_2 = \|A^{-1}\|_2 \cdot \|A\|_2 = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}$, λ 是 $A^T A$ 的特征值。
- 当 A 为对称矩阵时： $cond(A)_2 = \frac{|\lambda_{\max}|}{|\lambda_{\min}|}$

如何用于误差分析

对于方程 $Ax = b$ ， A 是精确的，添加 x 微小扰动后： $A(x + \delta x) = (b + \delta b)$ 。经过一系列变换后有扰动对原方程的影响：

$$\frac{\|\delta x\|}{\|x\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\delta b\|}{\|b\|} = cond(A) \cdot \frac{\|\delta b\|}{\|b\|}$$

b 精确，当添加 A 的微小扰动后： $(A + \delta A)(x + \delta x) = b$ 。经过计算后为：

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|\delta A\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} = \frac{\|A^{-1}\| \cdot \|A\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} \cdot \frac{\|\delta A\|}{\|A\|} = \frac{cond(A)}{1 - \|A^{-1}\| \cdot \|\delta A\|} \cdot \frac{\|\delta A\|}{\|A\|}$$

可以看到这个条件数就是我们在实际应用中的误差放大因子，条件数越大，微小扰动的影响就越大，数据越失真、不可靠。

根据条件数的大小来判断这个矩阵/方程组是良态还是病态。

西伯尔特矩阵(Hilbert 阵)可以用此方法验证该矩阵病良态。 $H_{ij} = \frac{1}{i+j-1}$

$$H_5 = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} \\ \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} \\ \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} & \frac{1}{9} \end{bmatrix} \quad H_n = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+1} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n} & \frac{1}{n+1} & \frac{1}{n+2} & \cdots & \frac{1}{2n-1} \end{bmatrix}$$

解线性方程组的迭代法

目录：

- 雅克比迭代法
- 高斯-赛德尔迭代法
- 迭代法的收敛性

直接法: 经过有限步运算后可求得方程组精确解的方法(不计舍入误差!)

直接法的基本思想是将一般的线性方程组化成与之等价的上三角或下三角形形式求解，其核心是几种重要的矩阵分解。

迭代法: 从解的某个近似值出发，通过构造一个无穷序列去逼近精确解的方法。(一般有限步内得不到精确解)

雅克比迭代法


$$eg. \quad \begin{cases} x_1 + 2x_2 + 3x_3 = 1 \\ 4x_1 + 5x_2 + 6x_3 = 2 \\ 7x_1 + 8x_2 + 9x_3 = 3 \end{cases} \xrightarrow[\text{获得迭代公式}]{\text{直接暴力移项}} \begin{cases} x_1^{(k+1)} = & & -2x_2^{(k)} & -3x_3^{(k)} + 1 \\ x_2^{(k+1)} = & -\frac{4}{5}x_1^{(k)} & & -\frac{6}{5}x_3^{(k)} + \frac{2}{5} \\ x_3^{(k+1)} = & -\frac{7}{9}x_1^{(k)} - \frac{8}{9}x_2^{(k)} & & + \frac{1}{3} \end{cases}$$

$$\text{也就是说: } x_i^{(k+1)} = \frac{1}{a_{ii}} \left(- \sum_{j=1, j \neq i}^n a_{ij} x_j^{(k)} + b_i \right)$$

高斯-赛德尔迭代法

$$eg. \quad \begin{cases} x_1 + 2x_2 + 3x_3 = 1 \\ 4x_1 + 5x_2 + 6x_3 = 2 \\ 7x_1 + 8x_2 + 9x_3 = 3 \end{cases} \xrightarrow[\text{获得迭代公式}]{\text{直接暴力移项}} \begin{cases} x_1^{(k+1)} = & & -2x_2^{(k)} & -3x_3^{(k)} + 1 \\ x_2^{(k+1)} = & -\frac{4}{5}x_1^{(k+1)} & & -\frac{6}{5}x_3^{(k)} + \frac{2}{5} \\ x_3^{(k+1)} = & -\frac{7}{9}x_1^{(k+1)} - \frac{8}{9}x_2^{(k+1)} & & + \frac{1}{3} \end{cases}$$

也就是说它与雅各比迭代法一样，只不过后面的 x 用上了前面的最新的 x 的值。

3) 
$$\begin{cases} 5x_1 + 2x_2 + x_3 = -12, \\ -x_1 + 4x_2 + 2x_3 = 20, \\ 2x_1 - 3x_2 + 10x_3 = 3. \end{cases} \quad \vec{x} = \begin{bmatrix} -4 & 3 & 2 \end{bmatrix}^T$$

(2) 用雅可比迭代法及高斯-赛德尔迭代法解此方程组，从 $[0, 0, 0]^T$ 开始迭代，写出前四次迭代的结果。

雅可比:
$$\begin{cases} x_1^{(k+1)} = -\frac{2}{5}x_2^{(k)} - \frac{1}{5}x_3^{(k)} - \frac{12}{5} \\ x_2^{(k+1)} = \frac{1}{4}x_1^{(k)} - \frac{1}{2}x_3^{(k)} + 5 \\ x_3^{(k+1)} = -\frac{1}{5}x_1^{(k)} + \frac{3}{10}x_2^{(k)} + \frac{3}{10} \end{cases} \Rightarrow \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \Rightarrow \begin{bmatrix} -2.4 \\ 5 \\ 0.3 \end{bmatrix} \Rightarrow \begin{bmatrix} -4.46 \\ 4.25 \\ 2.28 \end{bmatrix} \Rightarrow \begin{bmatrix} -4.556 \\ 2.745 \\ 2.46 \end{bmatrix} \Rightarrow \begin{bmatrix} -3.9914 \\ 2.625 \\ 2.0347 \end{bmatrix}$$

G-S:
$$\begin{cases} x_1^{(k+1)} = -\frac{2}{5}x_2^{(k)} - \frac{1}{5}x_3^{(k)} - \frac{12}{5} \\ x_2^{(k+1)} = \frac{1}{4}x_1^{(k+1)} - \frac{1}{2}x_3^{(k)} + 5 \\ x_3^{(k+1)} = -\frac{1}{5}x_1^{(k+1)} + \frac{3}{10}x_2^{(k+1)} + \frac{3}{10} \end{cases} \Rightarrow \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \Rightarrow \begin{bmatrix} -2.4 \\ 4.4 \\ 2.1 \end{bmatrix} \Rightarrow \begin{bmatrix} -4.58 \\ 2.805 \\ 2.0575 \end{bmatrix} \Rightarrow \begin{bmatrix} -3.9335 \\ 2.9878 \\ 1.9830625 \end{bmatrix} \Rightarrow \begin{bmatrix} -3.9911625 \\ 3.010528125 \\ 2.00150938 \end{bmatrix}$$

迭代法的收敛性(雅各比、高赛)

考虑三元线性方程组 $Ax = b$, $A = D + L + U$, L 是对角矩阵, L 是下三角矩阵, U 是上三角矩阵

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \begin{bmatrix} a_{11} & & \\ & a_{22} & \\ & & a_{33} \end{bmatrix} + \begin{bmatrix} & a_{21} & \\ a_{31} & a_{32} & \end{bmatrix} + \begin{bmatrix} & & a_{13} \\ & & a_{23} \end{bmatrix}$$

$A = D + L + U$, D 、 L 、 U 中的元素直接照抄 A 中对应位置的元素就行。

上面的两种迭代方式就能化为:

$$\begin{aligned} \text{雅各比: } x^{(k)} &= -D^{-1}(L+U)x^{(k-1)} + D^{-1}b \\ x^{(k)} &= B_J x^{(k-1)} + d_J \\ \text{高斯-赛德尔: } x^{(k)} &= -D^{-1}(Lx^{(k)} + Ux^{(k-1)}) + D^{-1}b \\ x^{(k)} &= -(D+L)^{-1}Ux^{(k-1)} + (D+L)^{-1}b \\ x^{(k)} &= B_G x^{(k-1)} + d_G \end{aligned}$$

他们的收敛条件如下:

- 充分条件-迭代矩阵 B 的某种范数满足 $\|B\| < 1$, > 1 的时候不一定发散
- 充要条件-迭代矩阵的谱半径 $\rho(B) < 1$
- 收敛速度为 $R(B) = -\ln \rho(B)$, 越小越快。

以雅各比中的例子说明:

B_J 就是暴力移项后右边的系数(不包含常数项):

$$B_J = \begin{bmatrix} 0 & -2 & -3 \\ -\frac{4}{5} & 0 & -\frac{6}{5} \\ -\frac{7}{9} & -\frac{8}{9} & 0 \end{bmatrix}$$

这个时候就能计算 $||G||$ 来判断迭代是否收敛了,

当然直接 $B_J = -D^{-1}(L + U)$ 直接计算出 B_J 也是可以的

雅各比迭代法和高斯-赛德尔迭代法的收敛性是不相关的！！

如何进行变换得到收敛矩阵？

变换行以达到严格对角占优： $|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$

定理：如果原方程中的A是严格对角占优矩阵，那么上述两种迭代法都收敛。

插值方法

目录：

- 拉格朗日插值
- 牛顿插值
- 埃尔米特插值

误差分析在每个插值函数末尾

拉格朗日插值

- 线性插值
- 二次插值
- n次插值

拉格朗日插值多项式

插值基函数： $L_j(x_k) = [1, k = j \text{ 或 } 0, k \neq j]$ 并且插值函数： $L_n(x) = \sum_{k=0}^n y_k l_k(x)$ 。

当为 n 次的时候:
$$l_k(x) = \frac{(x-x_0)(x-x_1)\cdots(x-x_{k-1})(x-x_{k+1})\cdots(x-x_n)}{(x_k-x_0)(x_k-x_1)\cdots(x_k-x_{k-1})(x_k-x_{k+1})\cdots(x_k-x_n)}$$

$n = 1$, 线性插值:
$$l_1(x) = y_0 \frac{x-x_1}{x_0-x_1} + y_1 \frac{x-x_0}{x_1-x_0}$$

$n = 2$, 二次插值:
$$l_2(x) = y_0 \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)} + y_1 \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)} + y_2 \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)}$$

插值余项

设插值多项式 $P_n(x)$ 满足 $P_n(x_i) = f(x_i) \quad (i = 1, 2, \dots, n)$, 也就是原始数据点两函数值相等, 记:

$$\omega(x) = (x-x_1)(x-x_2)\cdots(x-x_n) = \prod_{k=0}^n (x-x_k)$$

$$R_n(x) = f(x) - P_n(x), \quad R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega(x), \forall x \in [a, b]$$

$\xi \in [a, b]$ 与 x 有关

线性插值:
$$R(x) = \frac{1}{2} f''(\xi) (x-x_0)(x-x_1)$$

二次插值:
$$R_2(x) = \frac{1}{6} f'''(\xi) (x-x_0)(x-x_1)(x-x_2)$$

牛顿插值

差商

称 $f[x_0, x_1] = \frac{f(x_0) - f(x_1)}{x_0 - x_1}$ 为 $f(x)$ 关于 x_0, x_1 的一阶差商

称 $f[x_i, x_j] = \frac{f(x_i) - f(x_j)}{x_i - x_j}$ 为 $f(x)$ 关于 x_0, x_1 的一阶差商

称 $f[x_0, x_1, x_2] = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0}$ 为 $f(x)$ 关于点 x_0, x_1, x_2 的二阶差商

一般的, 称 $f[x_0, x_1, \dots, x_{n-1}, x_n] = \frac{f[x_1, x_2, \dots, x_n] - f[x_0, x_1, \dots, x_{n-1}]}{x_n - x_0}$

为 $f(x)$ 关于点 $x_0, x_1, \dots, x_n$ 的 n 阶差商

性质:

1.无序性: $f[x_0, x_1, x_2] = f[x_1, x_2, x_0] = f[x_2, x_0, x_1]$

2.与导数有关: $f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}, \xi \in [a, b]$

牛顿插值多项式、余项

$$\begin{aligned}
 P_n(x) &= f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots + f[x_0, x_1, \dots, x_n](x - x_0) \cdots (x - x_{n-1}) \\
 &= f(x_0) + \text{一阶} \times \omega_1(x) + \text{二阶} \times \omega_2(x) + \dots + \text{n阶} \times \omega_n(x)
 \end{aligned}$$

余项: $R_n(x) = f(x) - P_n(x) = f[x, x_0, x_1, \dots, x_n] \omega_{n+1}(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$

x_i	$f(x_i)$	1阶差商	2阶差商	3阶差商	4阶差商
x_0	$f(x_0)$				
x_1	$f(x_1)$	$f[x_0, x_1]$			
x_2	$f(x_2)$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$		
x_3	$f(x_3)$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	$f[x_0, x_1, x_2, x_3]$	
x_4	$f(x_4)$	$f[x_3, x_4]$	$f[x_2, x_3, x_4]$	$f[x_1, x_2, x_3, x_4]$	$f[x_0, x_1, x_2, x_3, x_4]$

比如2阶差商 $f[x_0, x_1, x_2]$ ，就是 $\frac{f[x_1, x_2] - f[x_1, x_0]}{f(x_2) - f(x_0)}$ ，也就是前面两个差商相减，然后除以这个2阶差商所在行的f(x)减去往上数(n)行的f(x)这里就是往上数的第2个也就是 x_0 对应的f(x)

埃尔米特插值