

第一课

1. 计算方法研究的是运用计算机来解决各种数学问题的近似计算方法与理论。是研究各类数学问题在一定范围内的数值解的方法，以及这些方法的误差传播规律、收敛性、稳定性，与如何在计算机上编程有效实现等问题的学科。
2. 误差：看第一课

第二课

计算方法的稳定性：用一个计算方法进行计算时，如果初始数据误差或某一步计算的误差在以后的计算过程中不增长，就称该方法数值稳定；否则，若误差增长，就称该方法数值不稳定

原则：

1. 避免相近数字相减
2. 加法中，防止大数吃小数
3. 避免采用绝对值很小的数做分母
4. 简化运算步骤，减小运算次数
5. 控制计算方法的误差传播，保证计算方法的稳定性

非线性方程的数值解法

目录：

- 二分法
- 一般迭代法：不动点迭代法、加速收敛迭代法
- 牛顿迭代法
- 弦截法

二分法

- 零点/根： x 满足 $f(x) = 0$ ，则 x 称为 f 的根
- m重零点/根： $f(x)$ 能分解为 $f(x) = (x - x^*)^m g(x)$ ， $g(x)$ 不为0，则 x^* 是 $f(x)$ 的m重根

二分法就是满足 $f(a)f(b) < 0$ 的前提下不断取中点，最终取得近似解。

一般迭代法

不动点迭代法

$f(x) = 0$ 变换为 $x = \Phi(x)$ ，也就是 $f(x) = \Phi(x) - x \Rightarrow$ 通过迭代： $x_{k+1} = \Phi(x_k)$ 。但这个迭代并不是一定收敛，所以给出以下收敛定理：

收敛性： $\Phi(x) \in [a, b]$ ，如果：

1. $\forall x \in [a, b]$ ，有 $\Phi(x) \in [a, b]$ (也就是大家都在自变量规定的正方形上)
2. $\exists L < 1, \forall x, y \in [a, b], |\Phi(x) - \Phi(y)| \leq L|x - y| \Rightarrow \frac{|\Phi(x) - \Phi(y)|}{|x - y|} \leq L$ ，也就是导数在此区间小于1。L称为压缩系数

那么 $\Phi(x)$ 在这个区间上有唯一不动点 x^* ，其中误差： $|x^* - x_k| \leq \frac{L^k}{1-L} |x_1 - x_0|$ ， L^k 中的 k 表示的是次方

局部收敛： $x \in U(x^*)$ ， x 在精确解 x^* 邻域附近，如果 $|\Phi'(x)| < 1$ ，则在 $U(x)$ 局部收敛。越接近，收敛越快

全局收敛： $x = \Phi(x)$ 满足收敛性质1、2(导数 < 1)，那么就是在 $[a, b]$ 的全局收敛

✎ 为求方程 $x^3 - x^2 - 1 = 0$ 在 $x_0 = 1.5$ 附近的一个根，设将方程改写成下列等价形式，并建立相应的迭代公式。

(1) $x = 1 + 1/x^2$ ，迭代公式 $x_{k+1} = 1 + 1/x_k^2$

(2) $x^2 = 1 + x^3$ ，迭代公式 $x_{k+1} = \sqrt{1 + x_k^3}$

(3) $x^3 = \frac{1}{x-1}$ ，迭代公式 $x_{k+1} = 1/\sqrt{x_k-1}$

试分析每种迭代公式的收敛性，并选取一种公式求出具有四位有效数字的近似根。

$f(1.4) \approx -0.216 < 0$ ， $f(1.5) \approx 0.125 > 0$ ， $\Rightarrow f(1.4)f(1.5) < 0$
 $f(x)$ 在 $[1.4, 1.5]$ 连续 } $\Rightarrow [1.4, 1.5]$ 为有根区间

(1) $\varphi(x) = 1 + \frac{1}{x^2}$ ， $\varphi'(x) = -\frac{2}{x^3}$ $\Rightarrow |\varphi'(x)| \leq |\varphi'(1.4)| = 0.219 < 1 \Rightarrow$ 收敛

(2) $\varphi(x) = \sqrt{1+x^3}$ ， $\varphi'(x) = \frac{3x^2}{2\sqrt{1+x^3}}$ $\Rightarrow |\varphi'(x)| \leq \frac{2 \times 1.5}{2\sqrt{1+1.5^3}} \approx 0.485 < 1 \Rightarrow$ 收敛

(3) $\varphi(x) = \frac{1}{\sqrt{x-1}}$ ， $\varphi'(x) = -\frac{1}{2(x-1)^{3/2}}$ $\Rightarrow |\varphi'(x)| \geq |\varphi'(1.5)| = 1.414 > 1 \Rightarrow$ 发散

由(1) $x_{k+1} = \sqrt[3]{1+x_k^3}$ ， $\mathbb{R}^+$ $x_0 = 1.5$ ， $x_1 = 1.481248024$ ， $x_2 = 1.471705173$ ， $x_3 = 1.466681794$ ，
 $x_4 = 1.4667047973$ ， $x_5 = 1.466682301$ ， $x_6 = 1.466682301$
 $\Rightarrow x^* \approx 1.4666$

收敛的阶数：

设迭代 $x_{k+1} = \Phi(x)$ ，满足 $\lim_{n \rightarrow \infty} \frac{x_{n+1} - x^*}{(x_n - x^*)^p} = k$ ， k 是常数。

则该迭代是 p 阶收敛

其中： $p = 1$ 是线性收敛， > 1 是超线性收敛， $= 2$ 是平方收敛。

定理： $x_{k+1} = \Phi(x_k)$ ，如果 $\Phi'(x^*) = \Phi''(x^*) = \dots = \Phi^{(p-1)}(x^*) = 0$ ， $\Phi^{(p)}(x^*) \neq 0$ ，则其 p 阶收敛。

斯特芬森加速迭代法

公式：
$$x_{k+1} = x_k - \frac{(\Phi(x_k) - x_k)^2}{\Phi(\Phi(x_k)) - 2\Phi(x_k) + x_k}$$

牛顿迭代法

牛顿法(切线法)-main

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \quad k = 0, 1, 2, \dots$$

收敛性(使用条件:导数=0): 若 $f'(x^*) \neq 0, f''(x^*) \neq 0$, 则牛顿法二阶收敛。且 $\lim_{k \rightarrow \infty} \frac{x_{k+1} - x}{(x_k - x^*)^2} = \frac{f''(x^*)}{2f'(x^*)}$

牛顿法的局部收敛性:

如果 $f'(x^*) \neq 0$, 则在 $U(x^*)$ 至少二阶收敛

$$\because \Phi'(x) = \frac{f(x)f''(x)}{[f'(x)]^2} \Rightarrow \therefore |\Phi(x^*)| = 0 < 1$$

$$\Phi''(x) = \frac{[[f''(x)]^2 + f(x)f'''(x)][f'(x)]^2 - 2f'(x)[f''(x)]^2 f(x)}{[f'(x)]^4} = \left| \frac{f''(x)}{f'(x)} \right|^2$$

区间收敛性: 设求 $f(x) = 0$, 且 $f(x)$ 二阶导数存在

如果: (1) $f(a)f(b) < 0$

(2) $\forall x \in [a, b], f'(x) \neq 0, f''(x) \neq 0$ (也就是不变号、凹凸性)

(3) 初值 $x_0 \in [a, b], f(x)f''(x_0) > 0$

则 (1) $f(x) = 0$ 在 $[a, b]$ 有唯一确定根

(2) 牛顿法二阶收敛

应用牛顿法于方程 $f(x) = 1 - \frac{a}{x^2} = 0$, 导出求 $\sqrt{a}$ 的迭代公式, 并用此公式求 $\sqrt{115}$ 的值.
(结果精确到小数点后6位)

$$y_{k+1} = y_k - \frac{f(y_k)}{f'(y_k)} = y_k - \frac{1 - \frac{a}{y_k^2}}{2 - \frac{2a}{y_k^3}} = \frac{y_k}{2} \left(1 + \frac{y_k^2}{a} \right)$$

$$\because f'(x) = 1 - \frac{2a}{x^3} \Rightarrow f'(x) = \frac{2a}{x^3}, \quad f''(x) = -\frac{6a}{x^4} < 0$$

显然, $x=0$ 为 $f(x)$ 的间断点, 当 $x > 0$ 时 $f'(x) \neq 0, f''(x) \neq 0$

要 $f(x_0)f''(x_0) > 0 \Rightarrow 0 < x_0 < \sqrt{a}$

当 $0 = 115$ 时, $y_0 = \frac{y_1}{2} \left(1 + \frac{y_1^2}{115} \right), y_0 \in (0, \sqrt{115})$

取 $y_0 = 10, \text{ 则 } y_1 = 10.55217391, y_2 = 10.7181839$

$y_3 = 10.7181839, y_4 = 10.7181839$

$\therefore \sqrt{115} \approx 10.7181839$



简化牛顿法(平行弦法)

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_0)}, \quad \text{即导数不变。}$$

牛顿下山法

$$x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)}, \quad \text{其中 } \lambda \text{ 为下山因子}$$

λ 从 1 开始取: $\lambda = 1, \frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \dots$, 直到有满足的下山条件: $|f(x_{k+1})| < |f(x_k)|$

弦截法(割线法)

$$x_{k+1} = x_k - \frac{f(x_k)}{f(x_k) - f(x_{k-1})} (x_k - x_{k-1})$$

即用差商(割线) $\frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$ 代替 $f'(x)$

注意: 此法必须给出两个初始值 x_0, x_1

解线性方程组的直接法

目录:

- 高斯消去法
- 列主元(全主元)高斯消去法
- LU分解法(矩阵三角分解法)
- 解三角方程组的追赶法

高斯消去法

高斯消去法: $\begin{bmatrix} | & & \\ A & & \\ | & & \end{bmatrix} \begin{bmatrix} | \\ X \\ | \end{bmatrix} = \begin{bmatrix} | \\ b \\ | \end{bmatrix}, \text{ 即 } AX=b$

写出增广矩阵 $[A:b]$, 进行行初等变换 $\rightarrow \begin{bmatrix} | & & & | \\ 0 & 1 & & | \\ 0 & 0 & 1 & | \\ 0 & 0 & 0 & | \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix}$

$[A:b]$

列主元消去法(对角线元素绝对值最大)

例: $Ax=b$, 求 x 并求 $\det(A)$

$$\left. \begin{matrix} 12x_1 - 3x_2 + x_3 = 15 \\ -18x_1 + 3x_2 - x_3 = -15 \\ x_1 + x_2 + x_3 = 6 \end{matrix} \right\} = \text{增广矩阵} \left[\begin{array}{cccc} 12 & -3 & 3 & 15 \\ -18 & 3 & -1 & -15 \\ 1 & 1 & 1 & 6 \end{array} \right] \rightarrow \left[\begin{array}{cccc} -18 & 3 & -1 & -15 \\ 12 & -3 & 3 & 15 \\ 1 & 1 & 1 & 6 \end{array} \right] \rightarrow \left[\begin{array}{cccc} -18 & 3 & -1 & -15 \\ 0 & -1 & \frac{7}{3} & 5 \\ 0 & 0 & \frac{11}{3} & 11 \end{array} \right] \text{解出} x = [1, 2$$

矩阵的LU分解

设A为n阶矩阵，若A的顺序主子式 $D_i \neq 0 (i = 1, 2, \dots, n - 1)$ ，则A可以分解为一个单位下三角矩阵L(主对角线为1)和一个上三角矩阵U，且分解唯一。即：

$$\left. \begin{matrix} A = LU \\ Ax = b \end{matrix} \right\} \Rightarrow LUx = b \Rightarrow \begin{matrix} Ly = b \\ Ux = y \end{matrix} \quad \begin{matrix} \text{先求这个} \\ \text{再求这个} \end{matrix} \quad A = \left[\begin{array}{cccc} 1 & 0 & 0 & 0 \\ \textcircled{1} & 1 & 0 & 0 \\ \textcircled{1} & \textcircled{3} & 1 & 0 \\ \textcircled{1} & \textcircled{3} & \textcircled{5} & 1 \end{array} \right] \left[\begin{array}{cccc} a_{11} & a_{12} & a_{13} & a_{14} \\ 0 & \textcircled{2} & \textcircled{2} & \textcircled{2} \\ 0 & 0 & \textcircled{4} & \textcircled{4} \\ 0 & 0 & 0 & \textcircled{6} \end{array} \right] \quad a_{1j} \text{就是} A \text{中的第一行的值}$$

LU两个矩阵中的值的解算根据上述序号来解。利用矩阵乘法来解(行×列=A中对应元素)

改进的平方根法(LU课外)：

1. 对称矩阵：

设A为n阶对称矩阵，且A的所有顺序主子式都不为零，则可以将A=LU中的U变换为 DL^T ，也就是 $A = LU = LDL^T$ ，其中L是单位下三角矩阵，D是**对角**矩阵(主对角线以外的元素全是零)。

先A=LU解出L和U，然后再 $A = LDL^T$ ，D的主对角元素就是U的主对角元素，然后就是 $Ly = b, DL^Tx = y$

2.对称正定矩阵：

设A为对称正定矩阵，则存在下三角矩阵， $A = LL^T$ ，此处的L和 $A = LU$ 中的L不一样

一般用(1): $Ly = b, DL^Tx = y$ 就行了，(2)用不上知道有这种方法就行，一切以 $A = LU$ 为主。

追赶法

对于严格对角占优的三对角矩阵，可分解为新的A=LU，其中L为下三角矩阵，U为单位上三角矩阵。 $Ax = b \Rightarrow Ux = y, Ly = b$ 。对比之前的LU分解法可以说是一样的，三对角矩阵也是这么分解。

$$A = \left[\begin{array}{cccccc} a_{11} & a_{12} & & & & \\ a_{21} & a_{22} & a_{23} & & & \\ & a_{32} & a_{33} & a_{34} & & \\ & & a_{43} & a_{44} & a_{45} & \\ & & & a_{54} & a_{55} \end{array} \right] = \left[\begin{array}{cccccc} a_{11} & & & & & \\ a_{21} & \textcircled{2} & & & & \\ & a_{32} & \textcircled{4} & & & \\ & & a_{43} & \textcircled{6} & & \\ & & & a_{54} & \textcircled{8} & \end{array} \right] \left[\begin{array}{cccccc} 1 & \textcircled{1} & & & & \\ & 1 & \textcircled{3} & & & \\ & & 1 & \textcircled{5} & & \\ & & & 1 & \textcircled{7} & \\ & & & & 1 & \textcircled{9} \end{array} \right]$$

本质和LU分解法一样，根据矩阵内的序号，用矩阵乘法定义来进行求解序号的值。为什么被单独列出来，是因为它利用了对角矩阵的稀疏性，

误差分析

目录：

- 矩阵的范数
- 矩阵的条件数

解线性方程组的误差分析

目录：

- 范数定义
- 向量、矩阵范数
- 方程组系数矩阵的条件数与误差分析

范数定义

设 R^n 是n维空间实向量， $||\cdot||$ 是一种函数关系，满足以下条件：

- $||A|| \geq 0, (||A|| = 0 \Leftrightarrow A = 0)$
- $||cA|| = |c| \cdot ||A||, c \in R$
- $||A + B|| \leq ||A|| + ||B||, ||x|| - ||y|| \leq ||x - y||$
- $||AB|| \leq ||A|| \cdot ||B||$

则称 $||\cdot||$ 是 R^n 上的一种范数(长度)

向量、矩阵范数

向量: $X = [x_1, x_2, \dots, x_n]^T, \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$ 称为向量的长度。

向量范数

设向量 $X \in R^n$ ，并且符合范数定义。

向量的n阶范数为： $||X||_n = (\sum_{i=1}^n |x^n|)^{\frac{1}{n}}$ ，无穷范数为 $||X||_\infty = \max |x_i|, 1 \leq i \leq n$ 。常用的范数是：一阶、二阶、无穷。

范数等价定理：设 $\|\cdot\|_A$ 和 $\|\cdot\|_B$ 是 R^n 中两种不同的范数，则存在与 x 无关的常数 C_1, C_2 ，使得 $C_1\|X\|_B \leq \|X\|_A \leq C_2\|X\|_B, X \in R^n$

向量序列的收敛定义

定义 5.2 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中一向量序列, $x^{(k)}=(x_1^{(k)},\cdots,x_n^{(k)})^T$,
 $x^*=(x_1^*,\cdots,x_n^*)^T \in \mathbb{R}^n$, 若 $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*, (i=1,2,\cdots,n)$, 则称 $\{x^{(k)}\}$ 收敛于 x^* . 记为 $\lim_{k \rightarrow \infty} x^{(k)} = x^*$ 或 $x^{(k)} \rightarrow x^* (k \rightarrow \infty)$.

由范数等价定理可证：设 $\|x\|$ 为 $\mathbb{R}^n$ 中任意一种向量范数，则

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \Leftrightarrow \lim_{k \rightarrow \infty} \|x^{(k)} - x^*\| = 0$$

要证明一个向量序列收敛，只需要选择一种具体范数去证明。选择适当的范数能使证明简化。

矩阵范数

设矩阵 $A \in R^{n \times n}$ 某个非负的实值函数 $N(A) = \|A\|$ 满足范数定义，则称 $N(A)$ 是 $R^{n \times n}$ 上的一个矩阵范数(长度/模)。

矩阵范数的性质可以由向量范数定义直接验证：

1. 设 $A \neq 0, \exists x \neq 0 \rightarrow Ax \neq 0$ ，根据向量范数性质有： $\|Ax\| > 0$ ，所以：

- $\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} > 0$
 - 当 $A = 0$ 时， $\exists x \neq 0$, 使得 $\|Ax\| = 0$ ，则 $\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = 0$
- 矩阵 A 的范数就是 $\frac{\|Ax\|}{\|x\|}$ 的最大值，当它也称为算子范数。

2. 根据以上可以验证其拥有的范数性质。

矩阵范数计算公式：

- A 的无穷范数，也称为行范数： $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$ ，就是求每一行绝对值相加，最大的那个就是行范数。
- $\|A\|_1$ ，一阶范数也就是列范数，就是每一列元素绝对值相加，和行范数翻过类。
- 2范数： $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$, $\lambda_{\max}$ 是 $A^T A$ 的最大特征值。注意这里根号下只有一个 λ ，后面只是表示它是 $A^T A$ 所有特征值中最大的那个而已。
- F范数： $\|A\|_F = (\sum_{i,j=1}^n a_{ij}^2)^{\frac{1}{2}}$ ，就是矩阵所有元素平方相加再开根。
- 矩阵特征值快速计算(二阶): $\lambda^2 - tr(A)\lambda + |A| = 0$

谱半径

矩阵特征值 $\lambda_i, i = 1, 2, \dots, n$ ，绝对值最大的就是矩阵的谱半径，记为 $\rho(A), \rho(A) = \lambda_{absmax}$

定理：

- 设有一方阵，任意的该矩阵范数都有 $\rho(A) < \|A\|$ ，也就是矩阵的谱半径小于任何该矩阵的范数。
- 如果 $A \in R^{n \times n}$ 是对称矩阵,则 $\rho(A) = \|A\|_2$
- (不怎么考)如果方阵 B 满足 $\|B\| < 1$ ，则 $I \pm B$ 为非奇异阵，且 $\|(I \pm B)^{-1}\| \leq \frac{1}{1-\|B\|}$

方程组系数矩阵的条件数与误差分析

- 条件数： $cond(A)_r = \|A^{-1}\|_r \cdot \|A\|_r, r = 1, 2, \infty$ 。
- 谱条件数(特殊形式) $cond(A)_2 = \|A^{-1}\|_2 \cdot \|A\|_2 = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}$, λ 是 $A^T A$ 的特征值。
- 当 A 为对称矩阵时： $cond(A)_2 = \frac{|\lambda_{\max}|}{|\lambda_{\min}|}$

如何用于误差分析

对于方程 $Ax = b$ ， A 是精确的，添加 x 微小扰动后： $A(x + \delta x) = (b + \delta b)$ 。经过一系列变换后有扰动对原方程的影响：

$$\frac{\|\delta x\|}{\|x\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\delta b\|}{\|b\|} = cond(A) \cdot \frac{\|\delta b\|}{\|b\|}$$

b 精确，当添加 A 的微小扰动后： $(A + \delta A)(x + \delta x) = b$ 。经过计算后为：

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|\delta A\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} = \frac{\|A^{-1}\| \cdot \|A\|}{1 - \|A^{-1}\| \cdot \|\delta A\|} \cdot \frac{\|\delta A\|}{\|A\|} = \frac{cond(A)}{1 - \|A^{-1}\| \cdot \|\delta A\|} \cdot \frac{\|\delta A\|}{\|A\|}$$

可以看到这个条件数就是我们在实际应用中的误差放大因子，条件数越大，微小扰动的影响就越大，数据越失真、不可靠。

根据条件数的大小来判断这个矩阵/方程组是良态还是病态。

西伯尔特矩阵(Hilbert 阵)可以用此方法验证该矩阵病良态。 $H_{ij} = \frac{1}{i+j-1}$

$$H_5 = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} \\ \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} \\ \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} & \frac{1}{9} \end{bmatrix} \quad H_n = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+1} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n} & \frac{1}{n+1} & \frac{1}{n+2} & \cdots & \frac{1}{2n-1} \end{bmatrix}$$

解线性方程组的迭代法

目录：

- 雅克比迭代法
- 高斯-赛德尔迭代法
- 迭代法的收敛性

直接法: 经过有限步运算后可求得方程组精确解的方法(不计舍入误差!)

直接法的基本思想是将一般的线性方程组化成与之等价的上三角或下三角形形式求解, 其核心是几种重要的矩阵分解。

迭代法: 从解的某个近似值出发, 通过构造一个无穷序列去逼近精确解的方法。(一般有限步内得不到精确解)

雅克比迭代法


$$eg. \quad \begin{cases} x_1 + 2x_2 + 3x_3 = 1 \\ 4x_1 + 5x_2 + 6x_3 = 2 \\ 7x_1 + 8x_2 + 9x_3 = 3 \end{cases} \xrightarrow[\text{获得迭代公式}]{\text{直接暴力移项}} \begin{cases} x_1^{(k+1)} = & -2x_2^{(k)} & -3x_3^{(k)} + 1 \\ x_2^{(k+1)} = & -\frac{4}{5}x_1^{(k)} & -\frac{6}{5}x_3^{(k)} + \frac{2}{5} \\ x_3^{(k+1)} = & -\frac{7}{9}x_1^{(k)} - \frac{8}{9}x_2^{(k)} & + \frac{1}{3} \end{cases}$$

也就是说: $x_i^{(k+1)} = \frac{1}{a_{ii}}(-\sum_{j=1, j \neq i}^n a_{ij}x_j^{(k)} + b_i)$

高斯-赛德尔迭代法

$$eg. \quad \begin{cases} x_1 + 2x_2 + 3x_3 = 1 \\ 4x_1 + 5x_2 + 6x_3 = 2 \\ 7x_1 + 8x_2 + 9x_3 = 3 \end{cases} \xrightarrow[\text{获得迭代公式}]{\text{直接暴力移项}} \begin{cases} x_1^{(k+1)} = & -2x_2^{(k)} & -3x_3^{(k)} + 1 \\ x_2^{(k+1)} = & -\frac{4}{5}x_1^{(k+1)} & -\frac{6}{5}x_3^{(k)} + \frac{2}{5} \\ x_3^{(k+1)} = & -\frac{7}{9}x_1^{(k+1)} - \frac{8}{9}x_2^{(k+1)} & + \frac{1}{3} \end{cases}$$

也就是说它与雅可比迭代法一样, 只不过后面的 x 用上了前面的最新的 x 的值。

3) 

(2) 用雅可比迭代法及高斯-赛德尔迭代法解此方程组, 从 $[0, 0, 0]^T$ 开始迭代, 写出前四次迭代的结果。

雅可比:
$$\begin{cases} x_1^{(k+1)} = -\frac{2}{5}x_2^{(k)} - \frac{1}{5}x_3^{(k)} - \frac{12}{5} \\ x_2^{(k+1)} = \frac{1}{4}x_1^{(k)} - \frac{1}{2}x_3^{(k)} + 5 \\ x_3^{(k+1)} = -\frac{1}{5}x_1^{(k)} + \frac{3}{10}x_2^{(k)} + \frac{3}{10} \end{cases} \Rightarrow \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \Rightarrow \begin{bmatrix} -2.4 \\ 5 \\ 0.3 \end{bmatrix} \Rightarrow \begin{bmatrix} -4.46 \\ 4.25 \\ 2.28 \end{bmatrix} \Rightarrow \begin{bmatrix} -4.556 \\ 2.745 \\ 2.467 \end{bmatrix} \Rightarrow \begin{bmatrix} -3.9914 \\ 2.6275 \\ 2.0347 \end{bmatrix}$$

G-S:
$$\begin{cases} x_1^{(k+1)} = -\frac{2}{5}x_2^{(k)} - \frac{1}{5}x_3^{(k)} - \frac{12}{5} \\ x_2^{(k+1)} = \frac{1}{4}x_1^{(k+1)} - \frac{1}{2}x_3^{(k)} + 5 \\ x_3^{(k+1)} = -\frac{1}{5}x_1^{(k+1)} + \frac{3}{10}x_2^{(k+1)} + \frac{3}{10} \end{cases} \Rightarrow \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \Rightarrow \begin{bmatrix} -2.4 \\ 4.4 \\ 2.1 \end{bmatrix} \Rightarrow \begin{bmatrix} -4.58 \\ 2.805 \\ 2.0575 \end{bmatrix} \Rightarrow \begin{bmatrix} -3.9335 \\ 2.9878 \\ 1.9830625 \end{bmatrix} \Rightarrow \begin{bmatrix} -3.991625 \\ 3.010528125 \\ 2.001509375 \end{bmatrix}$$

迭代法的收敛性(雅各比、高赛)

考虑三元线性方程组 $Ax = b$, $A = D + L + U$, L 是对角矩阵, L 是下三角矩阵, U 是上三角矩阵

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \begin{bmatrix} a_{11} & & \\ & a_{22} & \\ & & a_{33} \end{bmatrix} + \begin{bmatrix} & & \\ a_{21} & & \\ a_{31} & a_{32} & \end{bmatrix} + \begin{bmatrix} & a_{12} & a_{13} \\ & & a_{23} \\ & & \end{bmatrix}$$

$A = D + L + U$, D 、 L 、 U 中的元素直接照抄 A 中对应位置的元素就行。

上面的两种迭代方式就能化为:

$$\begin{aligned} \text{雅各比: } x^{(k)} &= -D^{-1}(L+U)x^{(k-1)} + D^{-1}b \\ x^{(k)} &= B_J x^{(k-1)} + d_J \\ \text{高斯-赛德尔: } x^{(k)} &= -D^{-1}(Lx^{(k)} + Ux^{(k-1)} + D^{-1}b \\ x^{(k)} &= -(D+L)^{-1}Ux^{(k-1)} + (D+L)^{-1}b \\ x^{(k)} &= B_S x^{(k-1)} + d_S \end{aligned}$$

他们的收敛条件如下:

- 充分条件-迭代矩阵 B 的某种范数满足 $\|B\| < 1$, > 1 的时候不一定发散
- 充要条件-迭代矩阵的谱半径 $\rho(B) < 1$
- 收敛速度为 $R(B) = -\ln \rho(B)$, 越小越快。

以雅各比中的例子说明:

B_J 就是暴力移项后右边的系数(不包含常数项):

$$B_J = \begin{bmatrix} 0 & -2 & -3 \\ -\frac{4}{5} & 0 & -\frac{6}{5} \\ -\frac{7}{9} & -\frac{8}{9} & 0 \end{bmatrix}$$

这个时候就能计算 $||G||$ 来判断迭代是否收敛了,

当然直接 $B_J = -D^{-1}(L + U)$ 直接计算出 B_J 也是可以的

雅各比迭代法和高斯-赛德尔迭代法的收敛性是不相关的！！

如何进行变换得到收敛矩阵？

变换行以达到严格对角占优： $|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$

定理：如果原方程中的A是严格对角占优矩阵，那么上述两种迭代法都收敛。

插值方法

目录:

- 拉格朗日插值
- 牛顿插值
- 埃尔米特插值

误差分析在每个插值函数末尾

拉格朗日插值

- 线性插值
- 二次插值
- n次插值

拉格朗日插值多项式

插值基函数： $L_j(x_k) = [1, k = j \text{ 或 } 0, k \neq j]$ 并且插值函数： $L_n(x) = \sum_{k=0}^n y_k l_k(x)$ 。

$$\text{当为}n\text{次的时候: } l_k(x) = \frac{(x-x_0)(x-x_1)\cdots(x-x_{k-1})(x-x_{k+1})\cdots(x_k-x_n)}{(x_k-x_0)(x-x_1)\cdots(x_k-x_{k-1})(x_k-x_{k+1})\cdots(x_k-x_n)}$$

$$n=1, \text{线性插值: } l_1(x) = y_0 \frac{x-x_1}{x_0-x_1} + y_1 \frac{x-x_0}{x_1-x_0}$$

$$n=2, \text{二次插值: } l_2(x) = y_0 \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)} + y_1 \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)} + y_2 \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)}$$

高次的时候会有龙格现象

插值余项

设插值多项式 $P_n(x)$ 满足 $P_n(x_i) = f(x_i) \quad (i = 1, 2, \dots, n)$, 也就是原始数据点两函数值相等, 记:

$$\omega(x) = (x-x_0)(x-x_1)(x-x_2)\cdots(x-x_n) = \prod_{k=0}^n (x-x_k)$$

$$R_n(x) = f(x) - P_n(x), \quad R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega(x), \forall x \in [a, b]$$

$\xi \in [a, b]$ 与 x 有关

$$\text{线性插值: } R(x) = \frac{1}{2} f''(\xi) (x-x_0)(x-x_1)$$

$$\text{二次插值: } R_2(x) = \frac{1}{6} f'''(\xi) (x-x_0)(x-x_1)(x-x_2)$$

牛顿插值

差商

$$\text{称} f[x_0, x_1] = \frac{f(x_0) - f(x_1)}{x_0 - x_1} \text{为} f(x) \text{关于} x_0, x_1 \text{的一阶差商}$$

$$\text{称} f[x_i, x_j] = \frac{f(x_i) - f(x_j)}{x_i - x_j} \text{为} f(x) \text{关于} x_0, x_1 \text{的一阶差商}$$

$$\text{称} f[x_0, x_1, x_2] = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0} \text{为} f(x) \text{关于点} x_0, x_1, x_2 \text{的二阶差商}$$

$$\text{一般的, 称} f[x_0, x_1, \dots, x_{n-1}, x_n] = \frac{f[x_1, x_2, \dots, x_n] - f[x_0, x_1, \dots, x_{n-1}]}{x_n - x_0}$$

为 $f(x)$ 关于点 $x_0, x_1, \dots, x_n$ 的 n 阶差商

性质:

$$1. \text{无序性: } f[x_0, x_1, x_2] = f[x_1, x_2, x_0] = f[x_2, x_0, x_1]$$

$$2. \text{与导数有关: } f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}, \xi \in [a, b]$$

牛顿插值多项式、余项

$$\begin{aligned}
 P_n(x) &= f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots + f[x_0, x_1, \dots, x_n](x - x_0) \cdots (x - x_{n-1}) \\
 &= f(x_0) + \text{一阶} \times \omega_1(x) + \text{二阶} \times \omega_2(x) + \dots + \text{n阶} \times \omega_n(x) \\
 \text{余项: } R_n(x) &= f(x) - P_n(x) = f[x, x_0, x_1, \dots, x_n] \omega_{n+1}(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)
 \end{aligned}$$

x_i	$f(x_i)$	1阶差商	2阶差商	3阶差商	4阶差商
x_0	$f(x_0)$				
x_1	$f(x_1)$	$f[x_0, x_1]$			
x_2	$f(x_2)$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$		
x_3	$f(x_3)$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	$f[x_0, x_1, x_2, x_3]$	
x_4	$f(x_4)$	$f[x_3, x_4]$	$f[x_2, x_3, x_4]$	$f[x_1, x_2, x_3, x_4]$	$f[x_0, x_1, x_2, x_3, x_4]$

比如2阶差商 $f[x_0, x_1, x_2]$ ，就是 $\frac{f[x_1, x_2] - f[x_1, x_0]}{f(x_2) - f(x_0)}$ ，也就是前面两个差商相减，然后除以这个2阶差商所在行的f(x)减去往上数(n)行的f(x)这里就是往上数的第2个也就是 x_0 对应的f(x)

埃尔米特插值

引入：为反映出被插值函数f(x)在插值节点处的变化趋势，不但要求插值多项式在节点处取已知函数值，而且还要求取已知导数值. 这类插值称为埃尔米特(Hermite)插值.

埃尔米特插值法的多项式定义，也就是所求的插值函数，它与牛顿插值法是完全雷同的，只不过它的差商表是需要根据已知条件来确定的。

比如下面的第一个例子，就是埃尔米特插值。因为有2个已知的x点的信息，所以称为两点3次插值

比如说我们有:

$$P_{(0)} = 0 \quad P_{(1)} = 1 \quad P_{(2)} = 1 \quad P_{(3)} = 2$$

那么我们构造的差商表如下:

①根据 X_i 的条件数, 写出其条件 比如 X_0 有2个条件
我们就写出2行:


x	$f(x)$	-阶
0	0	
0	1	

⇒ 补全:

x	$f(x)$	-阶
0	0	
0	1	

再写 x_1

x	$f(x)$	-阶
0	0	
0	1	
1	1	



上述式子可以得到插值公式 $P_3(x) = f(x_0) + 1 \times (x - x_0) + 0 \times (x - x_0)(x - x_1) + 1 \times (x - x_0)(x - x_1)(x - x_2)$

差商的计算:

$x \quad f(x) \quad -1阶 \quad -2阶 \quad -3阶$

$x_1 \quad f(x_1) \quad -1阶 \quad -2阶 \quad -3阶$

$x_2 \quad f(x_2) \quad -1阶 \quad -2阶 \quad -3阶$

$x_3 \quad f(x_3) \quad -1阶 \quad -2阶 \quad -3阶$

$x_4 \quad f(x_4) \quad -1阶 \quad -2阶 \quad -3阶$

往上数 [-3阶=3] 行

你所求的差商, 就等于前面两个数相减, 然后除以该差商行所对应的 x 的值减去往上数第几行的 x 的值的差。

eg. 求 -1阶 $f[x_2, x_1]$, 那就是:

$$\frac{f(x_2) - f(x_1)}{x_2 - x_1} \rightarrow \text{前边用 } f(x_2) \rightarrow \text{函数值/差商}$$

$$\frac{f(x_2) - f(x_1)}{x_2 - x_1} \rightarrow \text{所在行减去往上数 } [n-1] \text{ 行}$$

求三阶 $f[x_1, \dots, x_4]$:

$$\frac{f[x_3, x_2, x_1] - f[x_2, x_1, x_0]}{x_4 - x_1} \rightarrow \text{注意是下面减上面}$$

$$f(x, x, \dots, x) = \frac{f^{(n)}(x)}{n!}$$

0到 n , 共 $(n+1)$ 个 x , 注意没有下标!

它们是同一个 x !!!

这里就告诉你几阶差商与导数的关系

二项了次插值体现不完整,

下面有4次插值,

One more: $H_{(0)} = -1, H'_{(0)} = -2, H_{(1)} = 0, H'_{(1)} = 10, H_{(2)} = 40$, 求4次插值多项式.

直接写: $k \quad x \quad f(x) \quad -1阶 \quad -2阶 \quad -3阶 \quad -4阶$

k	x	$f(x)$	-1阶	-2阶	-3阶	-4阶
0	0	-1				
1	0	-1	-2			
2	1	0	$\frac{0-(-1)}{1-0} = 1$	③ 3		
3	1	0	① 10	④ 9	⑥ 6	
4	1	0	② 10	⑤ 20	⑦ 11	⑧ 5

怎么看连不连续?

你只要看你要的差商是几阶的, 比如③④, 都是二阶,

就从所在行往上2行加上

本身就是3行.

对于⑤: $x_0, x_1 \rightarrow$ 不连续, 用牛顿差商定义求

⑤: x_1, x_2 都是 x_1 , 所以连续. 用公式:

$$f[x_1, x_1, x_2] = \frac{f''(x_1)}{2!} = 20$$

①: 这里就是: $f[x_1, x_1] = \frac{f'(x_1)}{1!} = 10$

②: 这里和①一样, x_1 连续出现2次, $f[x_1, x_1] = f'(x_1) = 10$.

③: 这里是二阶差商, 因为这里是 x_1, x_2 交替出现, 不连续

所以 $f[x_1, x_0, x_0] = \frac{1 - (-2)}{1 - 0} = 3$

④: 这里也不连续, 所以 $f[x_1, x_1, x_0] = \frac{① - 1}{1 - 0} = \frac{10 - 1}{1} = 9$

⑤: 连续: 使用定义 $f[x_1, x_0, x_0] = \frac{f''(x_1)}{2!} = 20$

⑥⑦⑧ 均不连续 (往上数3, 3, 4行), 所以利用差商定义来做.

⑥: $\frac{④ - ③}{1 - 0} = 6 \quad ⑦: \frac{⑤ - ④}{1 - 0} = 11 \quad ⑧: \frac{⑦ - ⑥}{1 - 0} = 5$

求得4次公式为: $P_4(x) = f(0) + (-2)(x - x_0) + 3(x - x_0)(x - x_0) + 6(x - x_0)(x - x_0)(x - x_1) + 5(x - x_0)(x - x_0)(x - x_1)(x - x_1)$

其他插值

- 分段插值
- 3次埃尔米特插值
- 样条插值

前面的拉格朗日、牛顿、Hermite插值属于全局插值 (Global Interpolation), 即用一个多项式同时逼近整个区间上的所有节点。
由于节点增多时多项式次数升高, 容易出现Runge现象, 因此引入了分段插值 (Piecewise Interpolation):
把整个区间划分为若干小区间, 在每个小区间上使用低次多项式插值, 然后通过一定条件把这些局部多项式连接起来。

这三种插值都是将原来的数据点分成多段, 每次求插值的时候只取一个线段, 然后只取所选的线段的两个端点的值(函数值、导数值)

分段插值

分段插值就是一次拉格朗日插值。

3次埃尔米特插值

3次埃尔米特插值就是分段的3次埃尔米特插值。3次埃尔米特插值就是在每个线段(数据段)做一次2点3次埃尔米特插值。

每个线段中有3个数据点。

样条插值

样条插值就是分段三次Hermite插值的进一步改进，我们在工程中希望插值函数不仅具有良好的数据拟合，还希望它足够光滑(二阶导连续)。此外，3次埃尔米特插值还需要很多的一阶导数值，现实工程哪来的那么多导数数据？所以我们引入了不需要知道导数值的样条插值，它只需要知道数据点 $f(x_i) = c_i$ 即可。它本质上还是3次埃尔米特插值，不过：

- 核心思想是让曲线自己决定导数
- 导数光滑、边界条件为二阶导数等于0

下面图画告诉你怎么分段，怎么取点，告诉你8个未知数对应8个条件。

样条插值,有 $(0,0)$ $(1,1)$ $(2,0)$ 三个点,进行2段插值拟合。

因为要光滑地进行插值,所以 $S_1'(1) = S_2'(1)$ 。

1.原数据点条件 $\begin{cases} (0,0): 0 = a_1 \cdot 0 + b_1 \cdot 0 + c_1 \cdot 0 + d_1 \\ (1,1): 1 = a_1 + b_1 + c_1 + d_1 \\ (1,1): 1 = a_2 + b_2 + c_2 + d_2 \\ (2,0): 0 = 8a_2 + 4b_2 + 2c_2 + d_2 \end{cases}$

2.导数光滑条件: $\begin{cases} S_1'(1) = S_2'(1) \Rightarrow 3a_1 + 2b_1 + c_1 = 3a_2 + 2b_2 + c_2 \\ S_1''(0) = S_2''(0) \Rightarrow 6a_1 + 2b_1 = 6a_2 + 2b_2 \end{cases}$

3.边界条件: $\begin{cases} S_1''(0) = 0, 2b_1 = 0 \\ S_2''(2) = 0, 12a_2 + 2b_2 = 0 \end{cases}$

样条插值,有 $(0,0)$ $(1,1)$ $(2,0)$ 三个点,进行2段插值拟合。

因为要光滑地进行插值,所以 $S_1'(1) = S_2'(1)$ 。

1.原数据点条件 $\begin{cases} (0,0): 0 = a_1 \cdot 0 + b_1 \cdot 0 + c_1 \cdot 0 + d_1 \\ (1,1): 1 = a_1 + b_1 + c_1 + d_1 \\ (1,1): 1 = a_2 + b_2 + c_2 + d_2 \\ (2,0): 0 = 8a_2 + 4b_2 + 2c_2 + d_2 \end{cases}$

2.导数光滑条件: $\begin{cases} S_1'(1) = S_2'(1) \Rightarrow 3a_1 + 2b_1 + c_1 = 3a_2 + 2b_2 + c_2 \\ S_1''(0) = S_2''(0) \Rightarrow 6a_1 + 2b_1 = 6a_2 + 2b_2 \end{cases}$

3.边界条件: $\begin{cases} S_1''(0) = 0, 2b_1 = 0 \\ S_2''(2) = 0, 12a_2 + 2b_2 = 0 \end{cases}$

拟合

目录:

- 直线拟合
- m次代数曲线拟合
- 曲线拟合

上面几个曲线拟合其实都是使用最小二乘法思想来确定拟合曲线，而曲线拟合是拓展到**包含非线性组合模型**的最小二乘拟合。

如果用集合来看，曲线拟合是各种函数模型来进行拟合，而m次代数曲线拟合是使用这众多函数模型中的一种：m次多项式来进行拟合，直线拟合就是一次多项式拟合，关系就是：

- 直线拟合 $\subset$ m次代数曲线拟合 $\subset$ 曲线拟合

最小二乘法是什么？你可以简单理解为点到这个曲线的距离之和最小！

直线拟合

直线拟合： $y = kx + b$ ，形式如下：

$$\left. \begin{aligned} n \cdot b + \left(\sum_{i=1}^n x_i \right) \cdot k &= \sum_{i=1}^n y_i \\ \left(\sum_{i=1}^n x_i \right) \cdot b + \left(\sum_{i=1}^n x_i^2 \right) \cdot k &= \sum_{i=1}^n x_i y_i \end{aligned} \right\} \Leftrightarrow \begin{cases} b + k \cdot \bar{x} = \bar{y} \\ n \text{是要拟合的数据点的个数} \end{cases}$$

原始数据: $\begin{matrix} x_i & 1.00 & 1.25 & 1.50 & 1.75 & 2.00 \\ y_i & 5.10 & 5.79 & 6.53 & 7.45 & 8.46 \end{matrix}$

原始变换: $\ln y = b'x + \ln a$

变换后数据: $\begin{matrix} Y & 5.10 & 5.79 & 6.53 & 7.45 & 8.46 \\ Y & 1.629 & 1.756 & 1.876 & 2.008 & 2.135 \end{matrix}$

拟合方程: $Y = b'x + A$ ($y = kx + b$)

最小二乘法求形如 $y = ae^{bx}$ 的拟合方程

两个方程两个未知数。

m次代数曲线拟合

当数据呈现弯曲形式，直线就无法完美拟合了，这个时候就要引入多项式来进行拟合：

一次(直线拟合): $y = a_0 + a_1x$

二次(抛物线拟合): $y = a_0 + a_1x + a_2x^2$

三次(曲线拟合): $y = a_0 + a_1x + a_2x^2 + a_3x^3$

目标仍然是: $\sum_{i=1}^n (P_m(x_i) - y_i)^2$ 最小

这个时候我们就要求解 $a_0, a_1, a_3, \dots, a_n$ ，但是多项式拟合不应该次数太高，否则：

- 条件数变大
- 病态矩阵
- 数值不稳定

所以一般使用1次、2次，或者3次。5次以上很少用，要慎用！

曲线拟合

已知一组数据点 $(x_i, y_i) (i = 1, 2, \dots, n)$ ，且已知这组数据满足某一函数原型(经验公式) $y = F(a, x)$ ，其中 a 为待定向量。曲线拟合的最小二乘法就是要确定待定向量 a ，使总误差(残差平方和)最小。

曲线拟合可以用各种各样的函数模型！m次代数曲线拟合、直线拟合都只是比较常用的拟合模型而已，所以单独列出来了。

数值积分

目录：

- 数值积分的基本概念
- 机械求积公式
- 牛顿-柯特斯积分公式
- 复合积分公式

数值积分的基本概念

在实际应用中，因为很多时候你无法求出来原函数，所以根本不可能根据牛顿-莱布尼兹公式进行积分。所以我们要拓展其他求积公式。

机械求积公式

目录如下：

机械求积公式 (ΣA_k f(x_k))

|

+-- 插值型求积公式 (用插值多项式来定系数 A_k)

|

+-- 牛顿-柯特斯公式 (节点等距, 系数可查表)

|

+-- n=0 → 矩形公式

|

+-- n=1 → 梯形公式

|

+-- n=2 → Simpson公式 (抛物线公式)

|

+-- n=3 → 3/8 Simpson公式

1.机械求积公式

机械求积公式：

$$\int_a^b f(x)dx \approx \sum_{k=0}^n A_k f(x_k), \quad A_k \text{称为求积分系数，也叫权}$$

机械求积公式是下面所有公式的父类，他告诉了你这个求积公式的形式是怎样的，但是没有告诉你怎么求解这个系数：

- 只确定了求和公式的框架，没有告诉你节点 x_k 怎么选，系数 A_k 怎么定

m次代数精度：若一个机械求积公式对 $f(x) = x^j (j = 0, 1, \dots, m)$ 准确成立，但对 $f(x) = x^{m+1}$ 不准确成立，就说它具有m次代数精度

一个求积公式的代数精度越高，意味着它对更多的 函数准确成立，因此它的精确度也就越高

所谓代数精度，就是让 $\int_a^b f(x)dx$ 中 $f(x)$ 为 $1, x, x^2, \dots, x^m$ 时，等式都成立，然后查看等式是否成立

(1) 求代数精度 $\int_{-1}^1 f(x)dx = A_0 f(0) + A_1 f(1) + A_2 f(-1)$

$f(x)=1 \Rightarrow \int_{-1}^1 1dx = A_0 + A_1 + A_2$

$f(x)=x \Rightarrow \int_{-1}^1 xdx = 0 = (-1)A_1 + 0 + 1A_2 \Rightarrow \begin{cases} A_0 = \frac{2}{3} \\ A_1 = \frac{1}{3} \\ A_2 = \frac{1}{3} \end{cases}$

$f(x)=x^2 \Rightarrow \int_{-1}^1 x^2dx = \frac{2}{3} = \frac{1}{3}A_0 + 0 + \frac{1}{3}A_2 \Rightarrow A_0 = \frac{2}{3}, A_1 = \frac{1}{3}, A_2 = \frac{1}{3}$

因为原式给出3项，所以至少有2次精度： $ax^2+bx+c=0$

$\Rightarrow$ 验证精度： $\int_{-1}^1 x^3dx = 0 \Rightarrow \frac{1}{4}h^4 = \frac{1}{4}h^4 + \frac{1}{2}h^4 + \frac{1}{4}h^4 \Rightarrow$ 两边相等，二次精度

继续验证： $\int_{-1}^1 x^4dx = \frac{2}{5} \Rightarrow (\frac{1}{5}h^5 - \frac{1}{5}h^5) = \frac{1}{5}h^5 + \frac{1}{5}h^5 + \frac{1}{5}h^5 \Rightarrow$ 两边不等，三次精度

三次精度： $\int_{-1}^1 x^5dx = 0 \Rightarrow$ 左边 $= \frac{2}{6}h^6$ ，右边 $= \frac{1}{3}h^6 \Rightarrow$ 不相等，所以该式有三次精度

验证精度：
① 先求未知系数：
又 $f(x)=1, x, x^2, \dots, x^m$
② 继续往下验证

- n阶插值公式至少有n阶的代数精度
- 如果阶数为偶数，则至少有n + 1次代数精度(牛顿-科斯特公式)

2.插值型求积公式

在区间[a, b]上挑选n + 1个互不相同的节点 x_k ，在[a, b]上做函数 $f(x)$ 的n次拉格朗日插值多项式：

$$P_n(x) = \sum_{k=0}^n f(x_k)l_k(x), \quad l_k(x) = \prod_{j=0, j \neq k}^n \frac{x - x_j}{x_k - x_j}$$

此时用 $P_n(x)$ 逼近 $f(x)$ ，用 $\int_a^b P_n(x)dx$ 逼近 $\int_a^b f(x)dx$ 便得到：

$$\int_a^b f(x)dx \approx \int_a^b P_n(x)dx = \int_a^b \sum_{k=0}^n f(x_k)l_k(x)dx = \sum_{k=0}^n \{f(x_k) [\int_a^b l_k(x)dx]\}$$

与机械求积公式对比： $\int_a^b l_k(x)dx = A_k$

余项 $R = \int_a^b R_n(x)dx, \quad R_n(x) = \frac{f^{n+1}(\xi)}{(n+1)!} \omega_{n+1}(x), \omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$

你可以看到，使用拉格朗日插值公式来求解这个积分求和公式，它的形式还是和上面的机械公式一样，这里只是告诉你 x_k 怎么选， A_k 是什么。

3.矩形公式、梯形公式、Simpson公式

这三个公式就是牛顿-科斯特公式n不同取值的情况。先介绍这三种简单的公式，后面总结到牛顿-科斯特公式的时候，他们三个就都有一个共同的式子了。

1. 左中右矩形公式： $\int_a^b f(x)dx \approx (b-a)f(a)$ $\int_a^b f(x)dx \approx (b-a)f(\frac{a+b}{2})$ $\int_a^b f(x)dx \approx (b-a)f(b)$

左中右矩形公式就是右边 $f(x)$ 选的是那个点的区别：左 $f(a)$ 中 $f(\frac{a+b}{2})$ 右 $f(b)$

2. 梯形公式： $\int_a^b f(x)dx \approx \frac{b-a}{2}[f(a)+f(b)]$ $R_n = -\frac{(b-a)^3}{12}f''(\eta), \eta \in (a,b)$

3. 辛普森公式： $\int_a^b f(x)dx \approx \frac{b-a}{6}[f(a)+4f(\frac{a+b}{2})+f(b)]$ $R_n = -\frac{(b-a)^5}{2880}f^{(4)}(\eta), \eta \in (a,b)$

梯形公式是一阶插值公式，有一阶精度；辛普森公式是二阶插值公式，但是它是偶数，所以有三阶精度。

4.牛顿-科斯特公式(N-C公式)

设插值型求积公式中的节点等距离分布，记步长 $h = \frac{b-a}{n}$ ，则 $x_k = a + kh$ 。那么插值型公式就化简到下面形式：

$$A_k = \int_b^a l_k(x)dx = \int_a^b \prod_{j=0, j \neq k}^n \frac{x-x_j}{x_k-x_j} dx = \int_0^n \prod_{j=0, j \neq k}^n \frac{(a+th-(a+jh))}{(a+kh-(a+jh))} h dt$$
$$A_k = \int_0^n \prod_{j=0, j \neq k}^n \frac{(t-j)}{(k-j)} \frac{(b-a)}{n} dt = (b-a) \frac{1}{n} \frac{(-1)^{n-k}}{k!(n-k)!} \int_0^n \prod_{j=0, j \neq k}^n (t-j) dt$$
$$\int_b^a f(x)dx \approx \sum_{k=0}^n A_k f(x_k) = (b-a) \sum_{k=0}^n C_k^n f(x_k) \Rightarrow \text{这就是} n \text{阶} N-C \text{公式, } C_k^n \text{称为} N-C \text{系数}$$

下面给出已经算好的N-C系数表：

N-C 系数表

当n=1时，就是梯形公式，n=2就是辛普森公式(也叫1/3辛普森公式)，n=3时就叫3/8辛普森公式。

n	$C_1^{(n)}$	$C_2^{(n)}$	$C_3^{(n)}$	$C_4^{(n)}$	$C_5^{(n)}$	$C_6^{(n)}$	$C_7^{(n)}$	$C_8^{(n)}$	$C_9^{(n)}$
1	$\frac{1}{2}$	$\frac{1}{2}$							
2	$\frac{1}{6}$	$\frac{4}{6}$	$\frac{1}{6}$						
3	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$					
4	$\frac{7}{90}$	$\frac{32}{90}$	$\frac{12}{90}$	$\frac{32}{90}$	$\frac{7}{90}$				
5	$\frac{19}{288}$	$\frac{75}{288}$	$\frac{50}{288}$	$\frac{50}{288}$	$\frac{75}{288}$	$\frac{19}{288}$			
6	$\frac{41}{840}$	$\frac{216}{840}$	$\frac{27}{840}$	$\frac{272}{840}$	$\frac{27}{840}$	$\frac{216}{840}$	$\frac{41}{840}$		
7	$\frac{751}{17280}$	$\frac{3577}{17280}$	$\frac{1323}{17280}$	$\frac{2989}{17280}$	$\frac{2989}{17280}$	$\frac{1323}{17280}$	$\frac{3577}{17280}$	$\frac{751}{17280}$	
8	$\frac{989}{28350}$	$\frac{5888}{28350}$	$-\frac{928}{28350}$	$\frac{10496}{28350}$	$-\frac{4540}{28350}$	$\frac{10496}{28350}$	$-\frac{928}{28350}$	$\frac{5888}{28350}$	$\frac{989}{28350}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

系数表1-7 阶公式的求积系数恒大于 0，且N-C系数之和为 1，第8阶出现负数，开始变得不稳定。

复合求积公式

- 为什么需要符合求积公式？
 - 因为h过大时，牛顿-柯特斯公式精度较低。
- 为什么不采用高次的牛顿-柯特斯公式？
 - 高阶的柯特斯系数有正有负，可能导致两相近数作减法，使误差增大。

符合求积公式本质上还是使用低阶的N-C公式，只不过：

- 将要求积分的大区间 $[a, b]$ 划分为多个小区间 $[\alpha_i, \beta_i]$
- 在每个小区间 $[\alpha_i, \beta_i]$ 上运用一次低阶的N-C公式
- 将每个小区间所求得的结果加起来，就得到了大区间 $[a, b]$ 的积分求和值。

复合梯形公式： $\int_a^b f(x)dx \approx \frac{h}{2}(f(a) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b)) = T_n$

$$= \frac{\text{小区间长度}}{2} \left[f(\text{左端}) + 2 \sum f(\text{中间}) + f(\text{右端}) \right]$$

辛普森公式： $\int_a^b f(x)dx \approx \frac{h}{6} \left[f(a) + 4 \sum_{k=0}^{n-1} f(x_{k+\frac{1}{2}}) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b) \right]$

$$= \frac{\text{小区间长度}}{6} \left[f(\text{左端}) + 4 \sum f(\text{端点之间的中点}) + 2 \sum f(\text{中间端点}) + f(\text{右端}) \right]$$


复合梯形余项： $R_n(f) = -\frac{h^2}{12}(f'(b) - f'(a))$

辛普森余项： $R_n(s) = -\frac{1}{180} \left(\frac{h}{4} \right)^4 (f^{(3)}(b) - f^{(3)}(a))$

变步长梯形法

首先回顾梯形公式： $\int_a^b f(x)dx \approx \frac{b-a}{2}[f(a) + f(b)]$

变步长梯形公式就是在原来的结果上，再加上中点的函数值：



对于一个区间 $[a, b]$ ，先求 $T_1 = T_1$ 。在 (a, b) 中新增一个中间节点，以此类推，直到精度满足要求。

③ 计算过程：

(1) 对于区间 (a, b) ，先用梯形公式： $T_1 = \frac{b-a}{2}[f(a) + f(b)]$

(2) 再将 (a, b) 等分：先求 $T_2 = T_1 + \frac{b-a}{2}f(\frac{a+b}{2})$

(3) 再次等分：先求 $T_4 = T_2 + \frac{1}{4}[f(\frac{3a+b}{4}) + f(\frac{a+3b}{4})]$

然后 $T_2 = T_1 + \frac{b-a}{2}f(\frac{a+b}{2})$

T_n 为数值积分结果

所以我们有变步长的梯形公式：

教材给的： $T_{2n} = \frac{1}{2}T_n + \frac{h}{2} \sum_{k=0}^n f(x_{k+0.5})$

我总结的： $T_n = \frac{b-a}{2}[f(a) + f(b)]$

$$T_{2^n} = T_{2^{n-1}} + h \sum_{k=0}^n f(h(2k+1))$$

h 是步长： $T_{2^n} = T_{2^{n-1}} + (\frac{b-a}{2^n}) \sum_{k=0}^n f((\frac{b-a}{2^n})(2k+1))$

数值微分

目录：

- 差商法求导
- 拉格朗日法求导

和积分类似，实际问题中，对于离散的数据点无法进行传统有效的求导，也就是导数不可求，所以我们要寻找一种近似的方法进行求导。

数值微分就是利用数值方法（即不通过求导）来近似求解函数在某个点上的导数的方法

差商法求导

差商 $\leftrightarrow$ 斜率 $\xrightarrow{\text{近似}}$ 导数 $\Rightarrow$ 差商法求导

拉格朗日法求导

常微分方程初值问题的数值解法

目录：

- 基本概念
- 数值解法

基本概念

数值解法

目录：

- 欧拉法
- 改进欧拉法
- 龙格-库塔法

欧拉法

- 寻求解 $y(x)$ 在一系列离散点 $x_1 < x_2 < \dots < x_n < x_{n+1} < \dots$ 上的近似值 $y_1, y_2, \dots, y_n, y_{n+1}, \dots$
- 其中间距 $h_n = x_{n+1} - x_n$ 称为步长，当规定其为常数，有： $x_n = x_0 + nh$

欧拉公式: $y_{n+1} = y_n + hf(t_n, y_n)$

$y' = x^2 + 100y^2$, $y(0) = 0$, 取步长 $h = 0.1$, 计算到 $x = 0.5$

欧拉公式: $y_{n+1} = y_n + hf(t_n, y_n)$, f 就是 y' , t_n 就是 x_n

$\Rightarrow$ 代入: $y_{n+1} = y_n + 0.1(x_n^2 + 100y_n^2)$
 $= 0.1x_n^2 + 10y_n^2 + y_n$

① 初值: $y_{0.1} = 0.1(0)^2 + 10y_0^2 + y_0 = 0.0000$

$y_{0.2} = 0.1(0.1)^2 + 10(y_{0.1})^2 + y_{0.1} = 0.0010$

$y_{0.3} = 0.1(0.2)^2 + 10y_{0.2}^2 + y_{0.2} = 0.00501 \approx 0.0050$

$y' = \frac{t-y}{2}$, $y(0)=1$, 求 $x \in [0,1]$, $h=0.5$ 的数值解

$y_{n+1} = y_n + hf(t_n, y_n)$, t 就是 x

$y_{0.5} = y_0 + h \frac{x_0 - y_0}{2} = 1 + 0.5 \frac{0-1}{2} = 0.75$

$y_{1.0} = y_{0.5} + h \frac{x_{0.5} - y_{0.5}}{2} = 0.75 + 0.5 \frac{0.5-0.75}{2} = 0.6875$

改进欧拉法

先用欧拉法算出该点的值, 然后再迭代出此点更精确的值

这个公式就叫做梯形方法, 校正步只迭代一次就是这里所说的改进欧拉法。

$$\text{公式: } y_{n+1} = y_n + \frac{1}{2}h[f(x_n, y_n) + f(x_{n+1}, y_{n+1})]$$

$y' = \frac{t-y}{2}$, $y(0)=1$, 求 $x \in [0,1]$, $h=0.5$ 的数值解

$y_{n+1} = y_n + hf(t_n, y_n)$, t 就是 x

$y_{0.5} = y_0 + h \frac{x_0 - y_0}{2} = 1 + 0.5 \frac{0-1}{2} = 0.75$

$y_{1.0} = y_{0.5} + h \frac{x_{0.5} - y_{0.5}}{2} = 0.75 + 0.5 \frac{0.5-0.75}{2} = 0.6875$

改进欧拉法, 公式: $y_{n+1} = y_n + \frac{1}{2}h[f(x_n, y_n) + f(x_{n+1}, y_{n+1})]$

① 因为不知道 y_{n+1} 的值是什么, 所以先用欧拉法计算

② 再迭代一次: $y_{n+1} = y_n +$

计算过程: ① 先求初值—欧拉法. (预测值)

② 改进欧拉法迭代. (校正值)

后退欧拉法

后退欧拉法步骤和梯形方法一样, 只不过迭代公式是

$$y_{n+1} = y_n + hf(x_{n+1}, y_{n+1})$$

龙格-库塔法

太jb难记了, 不复习这个了